

Errores metodológicos en 01_Integración_Calidad_De_Datos.ipynb

Error 1 — Resample antes de validar rangos físicos

El notebook aplica el resample horario (promedio) sobre los datos crudos antes de ejecutar la validación de rangos físicos. Esto significa que una medición anómala, como una tensión V1 de 108 V (por debajo del mínimo regulatorio de 114.45 V), puede promediar con una medición válida de 124 V en la misma hora, produciendo un promedio de 116 V que supera el umbral y no es detectado ni eliminado. El dato anómalo queda enmascarado dentro del agregado y contamina silenciosamente el dataset limpio, haciendo que el filtro de calidad sea ineficaz sobre los valores que más debería controlar.

Error 2 — Fuga de datos por imputación temporal bidireccional

La función `imputar_por_bloque` rellena los huecos temporales de cada medidor usando `interpolate(method="time")`, seguido de `ffill()` y `bfill()`. La interpolación temporal es bidireccional: para calcular el valor de un instante faltante utiliza tanto observaciones pasadas como futuras, lo que introduce información del futuro en registros del pasado. Si posteriormente este dataset se usa para entrenar un modelo de predicción o clustering con componente temporal, el modelo aprende sobre valores que en la realidad no existían en ese momento, mejorando artificialmente las métricas de evaluación sin que el modelo haya aprendido nada real. Esto constituye fuga de datos en el sentido estricto del término.

Error 3 — Valores de rescate constantes e independientes del contexto

Cuando la interpolación no es suficiente para recuperar un hueco (por ejemplo, por ser demasiado largo), el notebook inyecta un valor fijo predefinido: `totalpowerfactor = 0.9`. Este valor no proviene de ninguna observación real del medidor ni de su comportamiento histórico; es una constante elegida arbitrariamente que representa un factor de potencia ideal. En medidores cuyo factor de potencia real difiere significativamente de ese valor, el rescate introduce un sesgo sistemático en la variable, distorsionando cualquier análisis de consumo, eficiencia energética o agrupamiento que dependa de ella. El resultado es un dataset sin ningún nulo que aparenta ser completo y de alta calidad, pero que contiene una fracción de datos sintéticos no declarados.